

Instrukcja dla informatyka

AI News Portal — co system robi

Zakres. Dokument opisuje **zachowanie funkcjonalne** wtyczki: co robi, w jakiej kolejności, na jakich danych i z jakimi granicami. Wymagania jakościowe są w **Wymaganiach нефunkcjonalnych**, formaty danych w **Schema — format danych**, a zachowanie samoczynne i awaryjne w **Instrukcjach systemowych**.

Odbiorca. Osoba wdrażająca lub utrzymująca witrynę WordPress. Zakłada się znajomość wtyczek, WP-Cron i podstaw PHP.

Źródło. Każde twierdzenie tego dokumentu pochodzi z kodu wtyczki w wersji podanej w stopce, nie z założeń projektowych.

AI News Portal 0.7.0 · licencja GPLv2
Wymagania: WordPress 6.5+ · PHP 8.1+

Spis treści

1 Czym jest ten system

Granice odpowiedzialności i zależności zewnętrzne.

2 Architektura wykonawcza

Warstwy, klasy i przepływ sterowania.

3 F1 — Pobieranie z kanałów

Od adresu RSS do wiersza w kolejce.

4 F2 — Filtrowanie i przygotowanie treści

Cztery bramki działające przed modelem.

5 F3 — Generowanie artykułu

Wywołanie modelu z wymuszonym schematem odpowiedzi.

6 F4 — Publikacja

Wpis, kategoria, idempotencja.

7 F5 — Warstwa publiczna

Centrum Wiedzy, artykuł, kategoria, wyszukiwanie.

8 F6 — Zadania cykliczne i zamek

Trzy fazy, budżet czasu, przejęcie po awarii.

9 F7 — Uprawnienia i ochrona żądań

Kto może co uruchomić.

10 F8 — Nagłówki bezpieczeństwa

Polityka uzupełniająca, nigdy nadpisująca.

11 Wdrożenie i weryfikacja

Kolejność kroków i kryteria odbioru.

1. Czym jest ten system

Wtyczka WordPressa, która buduje i utrzymuje portal wiedzy, czerpiąc materiał z publicznych kanałów RSS i przepisując go modelem językowym na własne artykuły.

W odróżnieniu od typowych wtyczek treściowych **nie czyta treści witryny, na której działa**. Materiał wchodzi wyłącznie z zewnątrz — z adresów RSS podanych w Ustawieniach — i wychodzi jako wpisy własnego typu treści `ainp_article`.

Granice odpowiedzialności

System odpowiada za	System NIE odpowiada za
Pobranie i odsianie materiału, wywołanie modelu, walidację odpowiedzi, publikację, prezentację archiwum i artykułu, pilnowanie dobowego sufitu wywołań.	Merytoryczną poprawność tekstów wytworzonych przez model, prawa autorskie do treści źródłowych poza cytowaniem adresu, dostępność serwisów zewnętrznych, uruchamianie WP-Cron przy braku ruchu na witrynie.

Zależność zewnętrzna

Jedna: **Google Gemini** przez punkt końcowy `v1beta/models/{model}:generateContent`. Model domyślny to `gemini-2.5-flash`, edytowalny w Ustawieniach. Klucz API dostarcza właściciel witryny; wtyczka nie zawiera żadnego klucza wbudowanego.

Wszystkie pozostałe zależności to rdzeń WordPressa: `wp_safe_remote_get`, WP-Cron, typy treści, taksonomie, `dbDelta`.

Trzy zabezpieczenia nienaruszalne — do nich sprowadza się przegląd każdej zmiany w tym systemie: nie tworzy duplikatów, nie publikuje odpowiedzi, która nie przeszła walidacji, nie zatrzymuje się na dobre z powodu pojedynczego błędu.

2. Architektura wykonawcza

Siedemnaście plików w `src/`, jedna tabela, jeden typ treści, jedna taksonomia. Zero wspólnego kodu z drugą wtyczką w paczce.


Warstwy

Warstwa	Klasy	Odpowiedzialność
Cykl życia	Plugin	Aktywacja, dezaktywacja, rejestracja typów treści, tabela, harmonogram.
Sieć	Http, Feed	Żądania wychodzące z limitami i budżetem czasu; rozbiór RSS 2.0 i Atom.
Odsiew	Filter, Dedup, Article	Słowa wykluczające i wymagane, powtórki po adresie i po treści, ekstrakcja tekstu.
Model	Gemini, Validator	Wywołanie z wymuszonym schematem, licznik dobowy, kontrola kontraktu odpowiedzi.
Orkiestracja	Runner	Trzy fazy przebiegu, zamek, budżet czasu, obsługa niepowodzeń.

Publikacja	Publisher	Wpis, termin taksonomii, idempotencja, usunięcie artykułu powitalnego.
Kokpit	Admin, Admin_Screen, Settings	Dwa ekrany, cztery akcje, zapis ustawień.
Front	Portal, szablony	Archiwum, artykuł, kategoria, wyszukiwanie na własnym parametrze.
Nagłówki	Security	Uzupełniające nagłówki bezpieczeństwa na widokach wtyczki.

AI News Portal — architektura wykonawcza

Jedna wtyczka, jedna tabela, jeden klucz API. Materiał wchodzi z kanałów RSS, wychodzi jako artykuł we własnym typie treści.



- Człowiek
- Zasób poza witryną
- Logika wtyczki
- Bramka — decyduje, czy iść dalej
- Integracja z WordPressem
- Trwałe dane w bazie

Architektura wykonawcza AI News Portal · pełna skala w pliku źródłowym `schematy/01-architektura-runtime.drawio`

3. F1 — Pobieranie z kanałów

Faza pierwsza przebiegu. Zamienia adresy RSS na wiersze w kolejce. **Nie wywołuje modelu i nic nie kosztuje.**

F1.1 Ustalenie listy kanałów

Lista pochodzi z opcji `ainp_sources`. Rozróżnienie jest istotne funkcjonalnie:

Stan opcji	Zachowanie
opcja nie istnieje (świeża instalacja)	Cztery kanały domyślne z <code>Settings::default_sources()</code> .
opcja zapisana jako pusta tablica	Pustka — pobieranie nie robi nic. Świadoma decyzja właściciela nie jest cofana.

Adresy są czyszczone: dopuszczalne tylko `http` i `https`, powtórzenia usuwane.

F1.2 Pobranie i rozbiór kanału

Żądanie `GET` przez `wp_safe_remote_get`, timeout 10 s, sufit odpowiedzi 4 MB, do 3 przekierowań. Obsługiwane są **RSS 2.0 i Atom**, wraz z `content:encoded` i `dc:date`.

Z jednego kanału bierzemy najwyżej 100 pozycji na przebieg.

F1.3 Normalizacja adresu i pierwsza bramka powtórek

Z adresu usuwane są parametry śledzące (`utm_*`, `gclid`, `fbclid` i pokrewne), po czym liczony jest `url_hash`. Kolumna ma klucz `UNIQUE`, więc powtórka nie ma jak wejść do tabeli nawet przy równoległych przebiegach.

To jest pierwsze z trzech zabezpieczeń nienaruszalnych, wymuszone na poziomie bazy, nie kodu.

4. F2 — Filtrowanie i przygotowanie treści

Faza druga. Odsiewa materiał i uzupełnia treść, gdy kanał podał samą zapowiedź. **Nadal bez modelu.** Partia to 10 pozycji.

F2.1 Filtr dwustronny — wykluczenia i wymagania

Dwie listy odpowiadające na przeciwne pytania:

Lista	Zakres przeszukania	Skutek trafienia
Słowa wykluczające	tytuł + zajawka + treść	odrzuć pozycję (skipped), powód w kolumnie note
Słowa wymagane	tytuł + zajawka	brak trafienia = odrzuć jako „poza tematem”

Porównanie idzie po tekście bez znaków diakrytycznych, z granicą słowa — formy odmienione muszą być wypisane osobno.

Pusta lista wymaganych wyłącza bramkę. Zachowanie zamierzone: właściciel, który wyczyści pole, dostaje filtr sprzed wariantu wymagań, a nie portal bez ochrony tematycznej mimo woli.

F2.2 Doczytanie treści ze strony źródłowej

Uruchamiane wyłącznie wtedy, gdy treść z kanału jest krótsza niż 1200 znaków. Żądanie GET, timeout 15 s, sufit 1 MB. Z dokumentu wybierany jest blok o największej gęstości tekstu; wynik jest przycinany do 20 000 znaków.

Adres kanoniczny ze strony docelowej zastępuje adres z kanału, jeśli się różni — to zamyka drogę powtórkom pod adresami przekierowującymi.


F2.3 Druga bramka powtórek — po treści

Liczony jest content_hash (SHA-256) z próbki 8 KB znormalizowanego tekstu. Kolumna ma klucz UNIQUE dopuszczający NULL, więc pozycje przed doczytaniem treści nie kolidują ze sobą.

Ta bramka łapie ten sam artykuł opublikowany w dwóch kanałach pod różnymi adresami.

Droga pozycji: od kanału RSS do opublikowanego artykułu

Cztery bramki odsiewają materiał ZANIM padnie pytanie do modelu. Każde wywołanie modelu kosztuje



Droga pozycji od kanału RSS do opublikowanego artykułu · pełna skala w `schematy/02-droga-pozycji.drawio`

5. F3 — Generowanie artykułu

Faza trzecia i jedyna płatna. Każda przerabiana pozycja to **jedno wywołanie modelu** z dobowej puli.

F3.1 Wybór pozycji i rezerwacja slotu

Brane są wiersze o statusie `new` z niepustą treścią, najwyżej 3 w jednym oknie budżetu. Bramka słów wymaganych jest sprawdzana **ponownie** w punkcie wyboru — ustawienia mogły się zmienić po pobraniu.

Slot rezerwowany jest PRZED wywołaniem. Żądanie ucięte po czasie również go zużywa — po stronie Google praca została wykonana.

F3.2 Budowa materiału i ochrona przed wstrzyknięciem

Materiał składa się z tytułu (do 300 znaków), adresu (do 500) i treści **uciętej do 12 000 znaków**. Treść jest opakowana w ogrodzenie `<<<MATERIAL_ZRODLOWY ... MATERIAL_ZRODLOWY>>>`, a wystąpienia znacznika w samym materiale są neutralizowane.

Sufit materiału jest wymogiem wydajnościowym, nie kosmetycznym: pozycje po 40 000 znaków dawały czas odpowiedzi ponad 30 s i przekraczały budżet przebiegu.

F3.3 Wymuszony schemat odpowiedzi

Żądanie ustawia `responseMimeType` na JSON oraz `responseSchema` z czterema polami: `title`, `lead`, `content`, `topic`. Pole `topic` jest typu `enum` zbudowanego z listy kategorii z Ustawień.

`temperature` = 0.4, `maxOutputTokens` = 8192, sufit odpowiedzi 1 MB.

Schemat Gemini **nie jest pełnym JSON Schema**. Każde nieznane pole wyraca całe żądanie na HTTP 400 — dopisanie `additionalProperties` zablokowało kiedyś publikację w całości. Lista dozwolonych kluczy jest pilnowana testem.

F3.4 Walidacja kontraktu odpowiedzi

Wymuszony schemat gwarantuje **składnię, nie sens**. Po stronie wtyczki sprawdzane są:

Pole	Warunek
<code>title</code>	od 5 do 140 znaków
<code>lead</code>	od 20 do 400 znaków
<code>content</code>	co najmniej 800 znaków
<code>topic</code>	dokładne dopasowanie do kategorii z Ustawień

Niespełnienie któregoś z warunków oznacza `failed` — **nie publikację z ostrzeżeniem**. To drugie zabezpieczenie nienaruszalne.

F3.5 Sufit dobowy

Opcja `ainp_usage` trzyma parę *data* + *licznik*. Po osiągnięciu wartości z pola „**Sufit wywołań AI na dobę**” (domyślnie 20) dalsze wywołania nie są podejmowane, a pozycja dostaje notatkę „*Wyczerpany sufit dobowy wywołań AI*”.

Licznik jest po stronie wtyczki i chroni przed odbiciem od limitu dostawcy, a nie zastępuje go.

6. F4 — Publikacja

Zamiana zwalidowanej odpowiedzi na wpis WordPressa.

F4.1 Wpis i powiązania

Powstaje wpis typu `ainp_article` ze statusem `publish` (albo `draft`, gdy w Ustawieniach włączono tryb szkiców). Tytuł i zajawka trafiają w pola natywne, treść w `post_content`. Kategoria z pola `topic` zostaje przypisana jako termin `ainp_topic`.

Zapisywane meta: `_ainp_item_id` (powiązanie z kolejką) oraz `_ainp_source_url` (adres źródła pokazywany w ramce artykułu).

F4.2 Idempotencja

Wiersz kolejki niesie `post_id`. Powtórna publikacja tej samej pozycji aktualizuje istniejący wpis zamiast tworzyć drugi.

F4.3 Usunięcie artykułu powitalnego

Przy **pierwszej publikacji ze statusem `publish`** kasowane są wpisy oznaczone meta `_ainp_demo`. Zapis szkicu artykułu powitalnego *nie* usuwa — portal nie może zostać bez treści.

7. F5 — Warstwa publiczna

Cztery widoki, zero JavaScriptu, jeden punkt załamania układu (46 rem).

F5.1 Adresy

Widok	Adres
Archiwum (Centrum Wiedzy)	/centrum-wiedzy/
Artykuł	/centrum-wiedzy/tytul-artykulu/
Kategoria	/centrum-wiedzy/kategoria/zywienie/
Wyszukiwanie	/centrum-wiedzy/?ainp_s=fraza

Człon `kategoria` jest konieczny: bez niego reguła pojedynczego artykułu i reguła kategorii mają identyczny wzorzec, a WordPress wybiera pierwszą — adres kategorii zwracał wtedy 404.

F5.2 Pierwszeństwo motywu

Szablony wtyczki wchodzi tylko wtedy, gdy motyw nie dostarcza własnych dla tego typu treści. Arkusz stylów wtyczki **nie ustawia kroju pisma ani tła** — te dziedziczy z motywu, żeby portal wyglądał jak reszta witryny.

F5.3 Wyszukiwanie i paginacja


Wyszukiwarka korzysta z **własnego parametru** `ainp_s`, nie z `s` WordPressa — dzięki temu nie miesza się z wyszukiwarką witryny. Archiwum stronicuje po 10 pozycjach; kanał RSS archiwum nie jest ograniczany tą wartością.

F5.4 Zdjęcia kart

Karta bierze zdjęcie **kategorii**, nie artykułu — wtyczka świadomie nie pobiera zdjęć ze stron źródłowych ze względu na prawa autorskie. Każda kategoria ma do 3 wariantów pliku, wybieranych rotacyjnie w obrębie listy, więc sąsiadujące karty tej samej kategorii nie powtarzają obrazu.

Przebieg cykliczny — trzy fazy pod jednym zamkiem

ainp_tick, co godzinie, tylko przy ruchu na witrynie. Budżet 20 s dzielony ¼ / ¼ / reszta. Przyciski panelu wołają te same fazy z własnymi budżetami.



Przebieg cykliczny · pełna skala w `schematy/04-przebieg-cykliczny.drawio`

8. F6 — Zadania cykliczne i zamek

Jedno zdarzenie, trzy fazy, jeden zamek, jeden budżet czasu.

F6.1 Harmonogram

Zdarzenie `ainp_tick`, powtarzalne, częstotliwość `hourly`. Planowane przy aktywacji **oraz domykane przy każdym starcie**, więc aktualizacja wtyczki nie gubi harmonogramu. Zapis Ustawień planuje dodatkowo jedno zdarzenie jednorazowe.

WP-Cron uruchamia się **przy ruchu HTTP**. Na witrynie bez odwiedzin portal nie pracuje — patrz rozdział 11.

F6.2 Zamek przebiegu

Opcja `ainp_run_lock` zakładana przez `INSERT IGNORE` — operację atomową na poziomie bazy. Wartość zamka to `czas + identyfikator przebiegu`. Zamek starszy niż 120 s może zostać przejęty przez inny przebieg (porównanie-i-zamiana po tokenie).

Zwolnienie zamka jest **warunkowe**: przebieg kasuje wyłącznie własny wpis. Bezwarunkowe kasowanie powodowało, że proces po przekroczeniu TTL zdejmował cudzy zamek i dwa przebiegi pracowały nad tą samą pozycją.

F6.3 Budżet czasu

Przebieg cykliczny ma 20 s, dzielone $\frac{1}{4}$ na pobranie, $\frac{1}{4}$ na przygotowanie, reszta na publikację. Budżet **przycina timeout żądania wychodzącego**; poniżej 8 s wywołanie modelu nie jest w ogóle podejmowane.

Przyciski panelu mają własne budżety: przygotowanie 15 s, publikacja 30 s.

Zasada: lepiej nie zaczynać niż zacząć i zostać uciętym — ucięte żądanie zużywa slot bez artykułu.

F6.4 Odzyskiwanie i ponowienia

Pozycja w stanie `processing` starszym niż 900 s wraca do `new`. Licznik `attempts` dopuszcza 3 próby samoczynne; potem pozycja czeka na ręczne „**Wznów nieudane**”.

Przy `failed` **treść zawsze zostaje w tabeli** — wznowienie nie wymaga ponownego pobrania ze źródła. To trzecie zabezpieczenie nienaruszalne.

9. F7 — Uprawnienia i ochrona żądań

Wtyczka nie wystawia własnych tras REST ani punktów publicznych zmieniających stan. Cała obsługa idzie przez kokpit.

F7.1 Uprawnienie

Wszystkie ekrany i akcje wymagają `manage_options`. Typ treści korzysta ze standardowego mapowania uprawnień wpisów, więc redaktor może edytować artykuły, nie mając dostępu do panelu wtyczki.

F7.2 Cztery akcje panelu

Akcja	Co uruchamia
„Pobierz teraz”	fazę F1 na pełnej liście kanałów
„Przygotuj treści”	fazę F2 na partii 10 pozycji
„Opublikuj teraz”	fazę F3 na maks. 3 pozycjach
„Wznów nieudane”	przywrócenie pozycji <code>failed</code> do kolejki

Każda akcja to żądanie `POST` chronione polem jednorazowym (`nonce`) i sprawdzeniem uprawnienia, wykonywane **pod tym samym zamkiem** co przebieg cykliczny.

F7.3 Przechowywanie klucza API

Klucz leży w osobnej opcji `ainp_key` z **wyłączonym autoładowaniem** — nie jest wczytywany przy każdym żądaniu do witryny. Nie trafia do żadnego widoku publicznego ani do dziennika.

10. F8 — Nagłówki bezpieczeństwa

Polityka **uzupełniająca, nigdy nadpisująca**: wtyczka wysyła wyłącznie to, czego nikt wcześniej nie ustawił.

F8.1 Zestawy według widoku

Widok	Nagłówki
strona portalu	Referrer-Policy, X-Content-Type-Options, X-Frame-Options: SAMEORIGIN, Permissions-Policy, Content-Security-Policy ograniczone do frame-ancestors 'self'
osadzenie (oEmbed)	bez X-Frame-Options i bez CSP — inaczej własne osadzenie przestałoby działać
kanal RSS	X-Content-Type-Options i Referrer-Policy
kokpit	nic — to nie jest widok wtyczki

Pełnego CSP wtyczka **nie narzuca**: na cudzym motywie z własnymi skryptami zablokowałaby stronę.

F8.2 Dwie drogi wyłączenia

Filtr `ainp_security_headers` (modyfikacja lub wyzerowanie tablicy nagłówków) oraz stała `AINP_NO_SECURITY_HEADERS` w `wp-config.php` (całkowite wyłączenie).

Nagłówków wysyłanych przez serwer WWW (nginx, Apache) PHP nie widzi. Wtyczka wysyła swoje bez zastępowania, więc w takim układzie może powstać duplikat nagłówka.

11. Wdrożenie i weryfikacja

Wymagania środowiska

Element	Wymaganie
WordPress	6.5 lub nowszy
PHP	8.1 lub nowszy
Baza	MySQL/MariaDB z obsługą InnoDB
Ruch wychodzący	HTTPS do kanałów RSS, stron źródłowych i generativelanguage.googleapis.com
Klucz API	Google Gemini, darmowy poziom wystarcza
Multisite	nieobsługiwane — odinstalowanie działa na pojedynczej witrynie

Kolejność wdrożenia

- 1

Instalacja i włączenie
Tabela, typy treści, przeładowanie reguł adresów, kategorie, artykuł powitalny, harmonogram — wszystko przy aktywacji.
- 2

Klucz API
Ustawienia → „Klucz API Gemini”.
- 3

Weryfikacja adresów
Otworzyć `/centrum-wiedzy/`. Gdy 404 — zapisać Bezpośrednie odnośniki.
- 4

Przebieg ręczny
Trzy przyciski panelu w kolejności od góry.
- 5

Zadanie cykliczne po stronie serwera
Zalecane na witrynach o małym ruchu — niżej.
- 6

Odnośnik w menu
Wygląd → Menu → panel „Artykuły” → „Zobacz wszystko” → pozycja **Centrum Wiedzy**.

WP-Cron na witrynie bez ruchu

Domyślnie WordPress uruchamia zadania przy okazji żądań HTTP. Na nowej witrynie oznacza to brak przebiegów. Zalecane rozwiązanie:

```
// wp-config.php
define( 'DISABLE_WP_CRON', true );

# zadanie systemowe, np. co 15 minut
*/15 * * * * curl -s https://twojastrona.pl/wp-cron.php?doing_wp_cron > /dev/null
```

Częstotliwość zadania nie musi odpowiadać częstotliwości `ainp_tick` — WordPress uruchomi zdarzenie dopiero, gdy nadejdzie jego pora.

Kryteria odbioru

#	Sprawdzenie	Oczekiwany wynik
1	Otwarcie /centrum-wiedzy/ zaraz po włączeniu	HTTP 200, widoczny artykuł powitalny i siedem kategorii
2	Otwarcie /centrum-wiedzy/kategoria/zywienie/	HTTP 200, komunikat o pustej kategorii albo lista
3	„Pobierz teraz”	Liczba nowych pozycji > 0, zero wywołań AI
4	„Przygotuj treści”	Część pozycji ze statusem pominięty i wypełnioną kolumną Powód , zero wywołań AI
5	„Opublikuj teraz”	Co najmniej jeden artykuł, licznik wywołań AI rośnie
6	Powtórne „Pobierz teraz” bez nowych wpisów w kanałach	Zero nowych pozycji — działa bramka powtórek
7	Wyłączenie wtyczki	/centrum-wiedzy/ zwraca 404, dane w bazie nietknięte
8	Ponowne włączenie	Artykuły i kolejka wracają w komplecie

Nie testować odinstalowania na witrynie produkcyjnej. Usunięcie wtyczki kasuje wszystkie artykuły, kategorie portalu i kolejkę bez możliwości przywrócenia.