

Wymagania нефunkcjonalne

AI FAQ Generator — jak system ma to robić

Zakres dokumentu. Nie *co* system robi (to opisuje **Instrukcja dla informatyka**), lecz *jak*: z jaką wydajnością, pod jakimi zabezpieczeniami, w jakim koszcie i z jaką odpornością na błędy.

Jak czytać. Każde wymaganie ma identyfikator (N1.1 , N2.3 ...), treść oraz **sposób weryfikacji** — czyli jak sprawdzić, że jest spełnione.

Wartości domyślne podane w tym dokumencie pochodzą z konfiguracji fabrycznej wtyczki i są zmienialne w ustawieniach, o ile nie zaznaczono inaczej.

AI FAQ Generator 1.1.0 · Wymaga WordPress 6.4+ i PHP 8.0+ · Licencja GPLv2

Spis treści

1	N1 — Wydajność	Czasy odpowiedzi, zachowanie przy dużej bazie, indeksy.
2	N2 — Bezpieczeństwo	Uprawnienia, walidacja, klucz dostawcy, nagłówki, wstrzyknięcia.
3	N3 — Koszt i przydział dostawcy	Trzy warstwy ochrony przed wyczerpaniem darmowej puli.
4	N4 — Niezawodność	Wznowienia, zamki, zachowanie przy równoległym dostępie.
5	N5 — Jakość odpowiedzi	Progi trafności i zasada odmowy zamiast zmyślania.
6	N6 — Zgodność i przenośność	Wersje, standardy WordPressa, licencja, wielojęzyczność.
7	N7 — Prywatność danych	Co opuszcza serwer klienta, co jest zapisywane, jak usunąć.
8	N8 — Utrzymywalność	Testy, migracje bazy, struktura kodu.

Podsumowanie liczbowe

Parametr	Wartość domyślna	Gdzie zmienić
Próg trafności (miękki)	0,70	Ustawienia → RAG
Próg trafności (twardy)	0,65	Ustawienia → RAG
Liczba fragmentów na odpowiedź	5	Ustawienia → RAG
Limit pytań gościa	10 na godzinę	Ustawienia → Limity
Dobowy sufit zapytań	12 (z puli 20 dostawcy)	Ustawienia → Limity
Liczba par w zestawie FAQ	zakres 5–20, domyślnie 20	Ustawienia → Narzędzie
Długość odpowiedzi	500 jednostek	Ustawienia → RAG
Swoboda odpowiedzi	0,2 (niska, przewidywalna)	Ustawienia → RAG
Wersja schematu bazy	6	migracja automatyczna

1. N1 — Wydajność

N1.1 Odpowiedź z pamięci podręcznej nie wywołuje dostawcy

Powtórzone pytanie obsługiwane jest z pamięci podręcznej, bez ruchu na zewnątrz i bez zużycia przydziału. W interfejsie oznaczane jako „odpowiedź z pamięci”.

Weryfikacja: zadać to samo pytanie dwukrotnie — drugie ma odpowiedzieć zauważalnie szybciej i nie podnieść licznika dobowego na Dashboardzie.

N1.2 Ponowne indeksowanie pomija treść niezmienioną

Fragmety o niezmienionej sumie kontrolnej nie są ponownie wysyłane do dostawcy. Powtórne indeksowanie witryny bez zmian w treści **nie generuje żadnych zapytań**.

Weryfikacja: uruchomić indeksowanie dwukrotnie pod rząd; drugi przebieg nie zmienia licznika zużycia.

N1.3 Indeksy bazy pod zapytania stronicujące

Listy Historii i Generowań korzystają z indeksu złożonego dopasowanego do porządku sortowania. Bez niego serwer bazy wykonywał sortowanie plikowe.

Pomiar z testów obciążeniowych: czas zapytania stronicującego spadł z zakresu 25–71 ms do wartości poniżej progu pomiaru (przyspieszenie do ok. 31×).

N1.4 Znane ograniczenie: wyszukiwanie liniowe

Dobór fragmentów przegląda bazę wiedzy liniowo. Czas rośnie proporcjonalnie do liczby fragmentów.

Zmierzone: przy 50 000 fragmentów dobór trwa ok. 5,8 s. Dla witryn typowej wielkości (do kilku tysięcy fragmentów) czas jest pomijalny.

Ograniczenie jest świadome — wektorowa baza danych byłaby dodatkową zależnością instalacyjną po stronie klienta. Przy witrynach powyżej kilkudziesięciu tysięcy fragmentów należy rozważyć zmianę podejścia.

N1.5 Indeksowanie nie blokuje żądania HTTP

Praca przerywana jest po przekroczeniu budżetu czasu, ze stanem zapisanym w bazie. Pobieranie wyrenderowanych stron przechodzi przez kolejkę obsługiwaną porcjami.

Uwaga eksploatacyjna: przy bardzo małej puli procesów PHP (np. `pm.max_children=2`) pobieranie własnych stron po HTTP może zakleszczyć pulę. Zalecane minimum to 4 procesy.

2. N2 — Bezpieczeństwo

N2.1 Bramka uprawnień na każdej trasie

Wszystkie trasy poza `POST /ask` wymagają uprawnień sprawdzanych po stronie serwera. Ukrycie przycisku w interfejsie nie stanowi zabezpieczenia i nie jest za takie uznawane.

Weryfikacja: wywołać trasę administracyjną bez logowania — oczekiwana odmowa, nie dane.

N2.2 Klucz dostawcy nigdy nie opuszcza serwera w stronę przeglądarki

Klucz nie jest zwracany w żadnej odpowiedzi ani wypisywany w interfejsie. Pole formularza ma typ ukrywający treść i po zapisaniu pokazuje wyłącznie informację o tym, że klucz istnieje.

Klucz **nie jest ładowany automatycznie** przy każdym żądaniu — pobierany jest dopiero w chwili faktycznego użycia.

Weryfikacja: otworzyć źródło strony ustawień i podejrzeć odpowiedzi REST — wartość klucza nie może w nich wystąpić.

N2.3 Odporność na wstrzyknięcie instrukcji przez treść strony

Treść pobrana z witryny przekazywana jest dostawcy **jako dane**, oddzielone od polecenia. Tekst umieszczony na stronie nie może przejąć roli instrukcji dla modelu.

Podatność tego rodzaju była wykryta i naprawiona w toku audytu bezpieczeństwa; zachowanie jest objęte testem.

N2.4 Nagłówki bezpieczeństwa podstrony publicznej

Podstrona generatora wysyłana jest z polityką bezpieczeństwa treści opartą o jednorazowy znacznik dla skryptów. Polityka **nie zawiera** dopuszczenia skryptów osadzonych w treści.

N2.5 Walidacja i oczyszczanie danych wejściowych

Każdy parametr trasy przechodzi walidację oraz oczyszczanie po stronie serwera. Zapytania do bazy budowane są wyłącznie z użyciem parametrów wiązanych.

Dostęp do zasobów sprawdzany jest pod kątem właściciela — identyfikator podany w żądaniu nie wystarcza do uzyskania cudzych danych.

Podatność tego typu (dostęp po samym identyfikatorze) była wykryta i naprawiona w audycie przed wydaniem.

N2.6 Trasa publiczna nie zapisuje bez ograniczeń

Zapis do dziennika pytań podlega limitowi. Trasa otwarta nie może posłużyć do niekontrolowanego zapełniania bazy klienta.

3. N3 — Koszt i przydział dostawcy

Wtyczka projektowana jest pod **darmowy** przydział dostawcy. Karta płatnicza nie jest wymagana do działania.

N3.1 Trzy warstwy ochrony przydziału

Warstwa	Działanie	Domyślnie
Pamięć podręczna	powtórzone pytanie bez wywołania dostawcy	włączona
Limit gościa	ogranicza liczbę pytań jednego odwiedzającego	10 / godzinę
Sufit dobowy	twardy limit zapytań wtyczki na dobę	12

Sufit dobowy ustawiony jest *poniżej* limitu dostawcy, aby pozostawić zapas na indeksowanie i generowanie zestawów.

N3.2 Rozdzielne pule dostawcy

Dostawca prowadzi **osobne** przydziały dla embeddingów i dla generowania treści. Wyczerpanie jednego nie blokuje drugiego — indeksowanie może działać mimo wyczerpania puli odpowiedzi.

N3.3 Widoczność zużycia

Bieżące zużycie dobowe prezentowane jest na Dashboardzie w formie „zużyto / limit”. Wartość odczytywana jest z licznika utrzymywanego przez wtyczkę.

Pułapka diagnostyczna. Przy wyczerpaniu przydziału *dobowego* dostawca zwraca sugerowany czas ponowienia liczony w sekundach. Jest on mylący — przydział odnawia się dopiero następnego dnia, nie po kilkudziesięciu sekundach.

Modele płatne. Modele oznaczone jako wymagające klucza płatnego mają na kluczu darmowym przydział zerowy. Ich wybór skutkuje błędem przy pierwszym pytaniu. Sprawdzenie połączenia weryfikuje poprawność klucza, *nie* przydział wybranego modelu.

4. N4 — Niezawodność

N4.1 Wznowienie przerwane indeksowania

Przerwanie z powodu budżetu czasu zapisuje stan i planuje automatyczne wznowienie. Przerwanie z powodu błędu albo limitu dostawcy **nie** jest wznowiane samoczynnie — wymaga decyzji obsługującego.

Rozróżnienie jest celowe: automatyczne ponawianie przy błędzie dostawcy mnożyłoby nieudane zapytania.

N4.2 Zamek na równoległym indeksowaniu

Jednoczesne uruchomienie indeksowania przez kilka procesów przepuszcza tylko jeden. Wcześniejsza wersja zamka miała lukę czasową między sprawdzeniem a zajęciem — przy dziesięciu równoległych próbach zamek „zdobywały” trzy. Po naprawie: jedna.

Weryfikacja: uruchomić kilka równoległych żądań indeksowania i sprawdzić, że pracuje jeden proces.

N4.3 Zamek publikacji

Równoległa publikacja zestawów szeregowana jest tak, aby przeszła jedna zmiana, a pozostałe otrzymały odpowiedź o konflikcie (HTTP 409).

Przed naprawą przy pięciu równoległych publikacjach trzy ginęły bez śladu (nadpisanie ostatniego zapisu).

N4.4 Spójność bazy wiedzy z treścią witryny

Usunięcie wpisu lub przeniesienie go do kosza usuwa powiązane fragmenty z bazy wiedzy. Odpowiedzi nie mogą powoływać się na treść już nieistniejącą.

Brak tego sprzątnia był usterką wykrytą w audycie i został naprawiony; zachowanie objęte testem.

5. N5 — Jakość odpowiedzi

N5.1 Odmowa zamiast zmyślania

Brak pokrycia w bazie wiedzy skutkuje jawną odmową. System nie sięga po wiedzę ogólną modelu. Wymaganie ma pierwszeństwo przed „użytecznością” odpowiedzi.

Weryfikacja: zadać pytanie ewidentnie spoza tematu witryny — oczekiwana odmowa.

N5.2 Progi trafności są kalibrowane, nie przypadkowe

Wartości progów (0,70 / 0,65) pochodzą z pomiarów na rzeczywistej witrynie. Wcześniejszy próg twardy 0,55 przepuszczał pytania o zbyt luźnym związku z treścią.

N5.3 Budżet rozumowania modelu

Ustawienie długości odpowiedzi obejmuje również wewnętrzne rozumowanie modelu. Przy zbyt niskim limicie model zużywa cały budżet na rozumowanie i zwraca odpowiedź pustą lub uciętą.

Objaw „ubogich odpowiedzi” miał właśnie tę przyczynę — udowodniono pomiarem, że rozumowanie pochłaniało 476 z 500 dostępnych jednostek.

6. N6 — Zgodność i przenośność

Wymaganie	Wartość
WordPress	6.4 lub nowszy
PHP	8.0 lub nowszy, z rozszerzeniem <code>mbstring</code>
Baza danych	MySQL 5.7+ lub MariaDB 10.3+
Licencja	GPLv2 — wyłącznie wersja 2; pełny tekst w pliku <code>LICENSE</code> w katalogu wtyczki
Nazewnictwo	tabele i opcje z prefiksem <code>aifaq_</code> — brak kolizji z innymi wtyczkami
Języki odpowiedzi	polski, angielski, niemiecki (treść odmowy konfigurowalna osobno)
Wymienność dostawcy	dostawca ukryty za interfejsem; dołożenie kolejnego nie wymaga zmian w rdzeniu

7. N7 — Prywatność danych

N7.1 Co opuszcza serwer klienta

Do dostawcy wysyłane są: fragmenty treści witryny (przy indeksowaniu), treść pytania oraz wybrane fragmenty (przy odpowiadaniu). **Nie są wysyłane** dane kont użytkowników ani zawartość bazy WordPressa poza treścią indeksowaną.

N7.2 Co jest zapisywane lokalnie

Dziennik pytań przechowuje treść pytania, odpowiedź, wynik dopasowania i — jeśli pytający był zalogowany — jego identyfikator. Dziennik można wyczyścić jednym działaniem z poziomu kokpitu.

N7.3 Deinstalacja bez śladu

Usunięcie wtyczki kasuje wszystkie jej tabele, opcje, dane tymczasowe oraz zadania cykliczne. W bazie klienta nie zostają dane osierocone.

Weryfikacja: po usunięciu sprawdzić brak tabel z prefiksem `wp_aifaq_` oraz brak opcji `aifaq_*`.

8. N8 — Utrzymywalność

Aspekt	Stan
Testy automatyczne	60 zestawów uruchamianych jednym poleceniem; warunek wydania: komplet zaliczony
Testy na żywym środowisku	pełne przejście cyklu życia produktu, 151 sprawdzeń
Migracje bazy	wersjonowany schemat (obecnie 6), migracja uruchamiana automatycznie
Struktura kodu	ładowanie klas wg przestrzeni nazw, podział na warstwy
Znany dług techniczny	brak wstrzykiwania zależności w trzech usługach; wyszukiwanie liniowe (N1.4)